

Корреляционный анализ

- Корреляционный анализ применяется для количественной оценки взаимосвязи двух наборов данных, представленных в безразмерном виде. Корреляционный анализ дает возможность установить, ассоциированы ли наборы данных по величине. Коэффициент корреляции, всегда обозначаемый латинской буквой r , используется для определения наличия взаимосвязи между двумя свойствами.
- Связь между признаками (по шкале Чеддока) может быть сильной, средней и слабой.
- Тесноту связи определяют по величине коэффициента корреляции, который может принимать значения от -1 до $+1$ включительно.

Величина коэффициента корреляции	0.1 - 0.3	0.3 - 0.5	0.5 - 0.7	0.7 - 0.9	0.9 - 1.0
Характеристика силы связи	слабая	умеренная	заметная	высокая	весьма высокая

средняясильная

Корреляционный анализ

- Коэффициент Пирсона

$$r_{xy} = \frac{\text{cov}_{xy}}{\sigma_x \sigma_y} = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 (y_i - \bar{y})^2}}$$

$\bar{x}$
 $\bar{y}$ выборочные средние

- КОРРЕЛ()
- ПИРСОН()
- Пакет анализа

Коэффициент корреляции

- Оценка значимости коэффициента корреляции
- По выборке рассчитываем значение статистики:
$$t_r = |r| \cdot \sqrt{\frac{n-2}{1-r^2}} = |-0.76| \cdot \sqrt{\frac{9-2}{1-0.76^2}} = 3,09$$

Т-распределение Стьюдента (Фрагмент таблицы)			
К	Вероятность: $\alpha = St(t) = P(T > t_{tabl})$		
	0,05	0,02	0,01
7	2,365	2,998	3,499

$t_r = 3.09 > t_{0.05,7} = 2.365$: коэфф. корреляции значим

Коэффициент корреляции

- Для определения критического значения статистики Стьюдента необходимо задать уровень значимости (часто 0,05) и число степеней свободы ($n-2$)
- Нулевая гипотеза (о равенстве коэффициента нулю) отклоняется, если расчетное значение статистики превышает критическое, или значение p -value не превосходит уровень значимости.

Корреляционный анализ

- Коэффициенты корреляции в зависимости от типа переменных

Тип шкалы		Мера связи
Переменная X	Переменная Y	
Интервальная или отношений	Интервальная или отношений	Коэффициент Пирсона
Ранговая, интервальная или отношений	Ранговая, интервальная или отношений	Коэффициент Спирмена
Ранговая	Ранговая	Коэффициент Кендалла
Дихотомическая	Дихотомическая	Коэффициент «φ»
Дихотомическая	Ранговая	Рангово-бисериальный
Дихотомическая	Интервальная или отношений	Бисериальный

Коэффициент Спирмена

- Используют также в тех случаях, когда о законе распределений ничего не известно, или есть основания предполагать, что одна или обе случайные величины имеют распределения заметно отличные от нормального или «засоренные» сильно отклоняющимися от основной массы значениями.

$$\rho_s = 1 - \frac{6 \sum d_i^2}{n^3 - n},$$

d – разность между рангами
сопряженных значений признаков

$$d = x_i - y_i$$

n – число парных наблюдений


Значимость коэффициента Спирмена

Правило. Для того чтобы при уровне значимости α проверить нулевую гипотезу о равенстве нулю генерального коэффициента ранговой корреляции ρ_r Спирмена при конкурирующей гипотезе $H_1: \rho_r \neq 0$, надо вычислить критическую точку

$$T_{кр} = t_{кр}(\alpha, k) \sqrt{\frac{1 - \rho_v^2}{n - 2}},$$

где n — объем выборки; ρ_v — выборочный коэффициент ранговой корреляции Спирмена; $t_{кр}(\alpha, k)$ — критическая точка двусторонней критической области, которую находят по таблице критических точек распределения Стьюдента (см. приложение 6), по уровню значимости α и числу степеней свободы $k = n - 2$.

Если $|\rho_v| < T_{кр}$ — нет оснований отвергнуть нулевую гипотезу. Ранговая корреляционная связь между качественными признаками не значима. Если $|\rho_v| > T_{кр}$ — нулевую гипотезу отвергают. Между качественными признаками существует значимая ранговая корреляционная связь.



Корреляционный анализ

- **Таблицы сопряженности**, или кросстабуляции (в SPSS crosstabs), служат для **описания связи двух или более номинативных (категориальных) переменных**. Примерами номинативных переменных являются пол (женский, мужской), тип поселения (город, ПГТ, село), ответ на произвольный вопрос (да, нет, затрудняюсь ответить) и т.д.
- Таблицы сопряженности неприменимы к непрерывным переменным, однако непрерывные значения тоже можно сгруппировать, разбить на дискретные интервалы. Например, возраст человека, который является непрерывным значением и потому хранится в непрерывной переменной, можно разбить на интервалы – возрастные группы.

Таблицы сопряженности

	Газ. вода: А	Газ. вода: В	
Пол: женщины	20 (40 %)	30 (60 %)	50 (50 %)
Пол: мужчины	30 (60 %)	20 (40 %)	50 (50%)
	50 (50 %)	50 (50 %)	100 100 %)

Таблицы сопряженности

В 1900 году Карл Пирсон предложил для проверки гипотезы тест (тест хи-квадрат Пирсона):

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - v_{ij})^2}{v_{ij}}, \quad \text{ожидаемые частоты}$$
$$v_{ij} = \frac{n_{i \cdot} \cdot n_{\cdot j}}{n}$$

$$n_{i \cdot} = \sum_{j=1}^s n_{ij}, \quad n_{\cdot j} = \sum_{i=1}^r n_{ij} \quad \text{маргинальные частоты}$$

Если $\chi^2 > \chi^2_{\alpha, (r-1)(s-1)}$ то гипотеза о независимости переменных **отвергается** (переменные зависимы).

Корреляционный анализ

- Ложная корреляция
- Удаление тренда (тенденции роста). Корреляция остатков

