

Лабораторная работа №1.

Описательная статистика. Корреляционный анализ

Цель работы: изучение дескриптивного анализа, корреляционного анализа и явлений ложной корреляции.

Среда выполнения: MS Excel, LibreOffice Calc, Jamovi, Statistica, RStudio, SPSS, Loginom, python и др. (по выбору студента).

Задание

1. Выбрать массив данных (ссылки представлены ниже в списке литературы, рекомендуется №7), описать параметры, зависимые и независимые переменные. Примечание: при переносе данных на лист MS Excel необходимо использовать импорт данных (учитывая разделитель столбцов и тип столбцов). Для выполнения лабораторной работы достаточно двух переменных, желательно использовать 3-4 (включая категориальные).
2. Провести дескриптивный анализ, оценить согласованность выборок с нормальным распределением.
3. Построить гистограммы выбранных атрибутов. Длину интервала рассчитать с помощью формулы Стерджесса.
4. Изучить пример построения таблиц сопряженности (п. 4 из списка литературы). Выбрать в рассматриваемой выборке категориальные переменные или перевести числовые переменные в категориальные, провести анализ с помощью таблиц сопряженности. Описать результаты.
5. Провести корреляционный анализ. Если рассматриваемые выборки не согласуются с нормальным распределением – провести ранговый корреляционный анализ.
6. Оценить значимость коэффициентов корреляции.
7. Выделить сильно- и слабокоррелированные признаки.
8. Интерпретировать результаты.
9. На сайте <http://www.tylervigen.com/spurious-correlations> выбрать массив данных, оценить ложную корреляцию между параметрами. Проверить гипотезу о причинах возникновения ложной корреляции. Описанная ниже последовательность шагов соответствует порядку выполнения задания в MS Excel. При работе на других платформах можно использовать библиотечные функции для построения регрессионных моделей.

9.1. Восстановить таблицу данных и построить диаграммы, соответствующие массиву из раздела «ложная корреляция». *Примечание:* вместо отсчетов по годам можно использовать отсчеты

«1», «2» и т.д. Если данные двух рядов сильно отличаются друг от друга – использовать вспомогательную ось с другим масштабом (правой кнопкой мыши щелкнуть на ряд на диаграмме, выбрать «формат ряда данных» и «отобразить по вспомогательной оси»).

9.2 Добавить наиболее подходящие линии тренда для каждого из рядов. Отобразить уравнения на диаграмме. При работе в MS Excel осуществляется добавление тренда, на других платформах можно построить линию регрессии.

9.3 Подсчитать новые значения зависимых переменных по построенным моделям.

9.4 Подсчитать остатки для каждого из рядов (« y исходное минус y предсказанное (посчитанное по уравнению)»).

9.5 Подсчитать стандартизированные остатки.

9.6 Построить график остатков, гистограмму стандартизированных остатков.

9.7 Определить корреляцию остатков. Можно использовать функцию MS Excel KОРРЕЛ() или «Корреляция» из «Анализа данных».

9.8 Оценить значимость коэффициента корреляции.

9.9 Интерпретировать результаты. Сформулировать выводы о причинах ложной корреляции.

10. Оформить отчет.

Содержание отчета

1. Титульный лист.
2. Цель работы.
3. Описание исходных данных.
4. Результаты дескриптивного анализа.
5. Анализ результатов таблиц сопряженности.
6. Результаты корреляционного анализа.
7. Оценка и интерпретация результатов.
8. Пример и интерпретация ложной корреляции.

Список литературы и ссылки на материалы

1. Айвазян С.А. Методы эконометрики. – М.: Магистр: - ИНФРА-М, 2010. – 512 с.
2. Группировка и формула Стерджесса. <http://univer-nn.ru/zadachi-po-statistike-primeri/gruppirovka-formula-sterdzhessa/>
3. Проверка статистических гипотез в MS Excel. <http://excel2.ru/articles/proverka-statisticheskikh-gipotez-v-ms-excel>
4. Таблицы сопряженности. <http://excel2.ru/articles/kriteriy-nezavisimosti-hi-kvadrat-v-ms-excel>
5. Корреляция в Excel. <https://excel2.ru/articles/korrelyaciya-i-kovariaciya-v-ms-excel>
6. <https://www.kdnuggets.com/datasets/index.html>
7. <http://archive.ics.uci.edu/ml/datasets>
8. <http://www.tylervigen.com/spurious-correlations>

Перечень вопросов для подготовки к защите.

1. Оценка согласованности выборки с нормальным распределением. Среднее, мода, асимметрия, эксцесс. Симметричные и несимметричные распределения. Гистограмма. Связь гистограммы и функции плотности распределения вероятностей. Ящики с усами.
2. Корреляционный анализ числовых, категориальных и ранговых переменных. Коэффициенты корреляции Пирсона, Спирмена, Кендалла. Причины ложной корреляции.
3. Значимость коэффициента корреляции.
4. Таблицы сопряженности.
5. Понятия «независимости» и «некоррелированности»: в каких случаях некоррелированность эквивалентна независимости, в каких случаях независимость эквивалентна некоррелированности.

Примеры практических заданий

1. Оценить зависимость между переменными по выборке. По диаграмме рассеивания оценить значение коэффициента корреляции. Оценить значимость коэффициента корреляции. Привести пример диаграммы рассеивания для сильно-/слабокоррелированных признаков, для независимых признаков, некоррелированных, но зависимых и т.п.
2. По гистограмме оценить параметры выборки. По гистограмме и значениям параметров выборки оценить, согласуется ли выборка с нормальным распределением. Те же вопросы для ящика с усами.
3. Таблицы сопряженности. Сформулировать условия и правила применения для оценки зависимости переменных. Для представленных данных описать схему проведения расчетов. Сформулировать гипотезу, описать процедуру подготовки данных, правила, по которым гипотеза отвергается или принимается. По представленным результатам аргументировать решение об отклонении гипотезы.